

Sessão 4 - Visualização de dados

Treinamento em R - SEFAZ RS-WB DIME

Thiago Scot

The World Bank | Fevereiro 2025




Índice

- Introdução
- A gramática dos gráficos
- Gráficos de barras
- Gráficos de linha
- Codificações de texto
- Gráficos de dispersão
- Conclusão

Introdução

Introdução


Sobre esta sessão



Introdução


Visualização de dados no pipeline de trabalho com dados

- Comparada a outros tipos de saídas, a visualização de dados envolve uma etapa extra após a manipulação de dados: produzir a visualização em si
- Também usamos código R para produzir visualizações de dados
- A entrada para esse código é um dataframe manipulado, um dataframe que está pronto para ser usado



Visualização de dados em R


- Usaremos o pacote `ggplot2` para criar visualizações de dados
- O `ggplot2` facilita muito a produção de gráficos em R
 - Ele segue uma sintaxe baseada em uma descrição do gráfico que você quer obter
 - Esta sintaxe é chamada de **gramática dos gráficos**, um método de referência de definição de visualização de dados em programação estatística



A gramática dos gráficos


A gramática dos gráficos

A gramática dos gráficos no `ggplot2`




The screenshot shows an RStudio window with a data frame named 'df_'. The data frame has two columns: 'mes_emissao' and 'total'. The data is as follows:

	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6



```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```



A gramática dos gráficos

A gramática dos gráficos no `ggplot2`

data-visualization-br.Rmd x 4-data-visualization.Rmd x df_

Filter


	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6

O primeiro argumento do `ggplot()` é o dataframe de entrada (`df_group_month`)

`ggplot()`: inicializa o gráfico

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```

Símbolo de "+" adiciona elementos ao gráfico



A gramática dos gráficos

A gramática dos gráficos no `ggplot2`

data-visualization-br.Rmd x 4-data-visualization.Rmd x df_

Filter


	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6

Eixo-y (total)

Eixo-x (Mes)

O segundo argumento do `ggplot()` define a "estética"

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```



A gramática dos gráficos

A gramática dos gráficos no `ggplot2`


data-visualization-br.Rmd x 4-data-visualization.Rmd x df_

Filter

	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6


geom_col() determina a geometria do gráfico)

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```



A gramática dos gráficos

A gramática dos gráficos no `ggplot2`




The screenshot shows a data frame with three columns: 'id', 'mes_emissao', and 'total'. The first three rows are visible, showing data for months 10, 11, and 12.

	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```

labs() determina as legendas/títulos



Gráficos de barras

Gráficos de barras

Exercício 1a: Criar um gráfico de barras básico

1. Abra um novo script para esta sessão clicando em `File` >> `New File` >> `R Script`
2. Carregue o `ggplot2`


```
library(ggplot2)
```

1. Produza um gráfico de barras básico com o seguinte código:

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês")
```

Gráficos de barras


Este resultado deve ser exibido no painel inferior direito da sua janela do RStudio



Gráficos de barras

Este gráfico parece aceitável, mas pode ser melhorado:

- `mes_emissao` é uma variável que representa meses, mas o R não sabe disso e está mostrando simplesmente os números
- Podemos centralizar o título
- Devemos adicionar rótulos dos eixos (em vez de apenas "mes_emissao" e "vicms")
- Muita informação no fundo: cor cinza, linhas



Gráficos de barras


Exercício 1b: Melhore seu gráfico de barras

1. Use o seguinte código para melhorar a estética do seu gráfico

```
ggplot(base_nfe) +  
  aes(x = as.factor(mes_emissao),      #as.factor() informa que mes_emissao não é número mas categorias  
      y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês",  
        # título do eixo x  
        x = "Mês",  
        # título do eixo y  
        y = "Valor ICMS (R$)") +  
  # dizendo ao R para não quebrar o eixo x  
  scale_x_discrete(labels = c("Outubro", "Novembro", "Dezembro")) +  
  # remove linhas de fundo e cor  
  theme_classic() +  
  # centralizando o título do gráfico  
  theme(plot.title = element_text(hjust = 0.5))
```

Gráficos de barras

Agora está melhor:



Gráficos de barras

Exercício 1c: salve seu gráfico

Agora que seu gráfico está bom, você pode salvá-lo em uma saída com `ggsave()`

1. Use este código para salvar seu gráfico:

```
ggsave("base_nfe_totals.png",  
       width = 20,  
       height = 10,  
       units = "cm")
```

Gráficos de barras

- `ggsave()` por padrão salva o último gráfico que você produziu
- O primeiro argumento em `ggsave()` é o nome do arquivo em que salvamos o gráfico. Também podemos usar caminhos de arquivo aqui
- O resto são argumentos opcionais que definem as dimensões da imagem que você exporta, é melhor defini-los para que a imagem tenha as proporções e tamanho de texto corretos

Name	Date modified	Type	Size
1-introduction-to-r_cache	9/19/2023 3:30 AM	File folder	
2-data-wrangling_cache	9/19/2023 3:46 PM	File folder	
3-descriptive-statistics_cache	9/20/2023 7:01 PM	File folder	
4-data-visualization_cache	9/20/2023 11:23 PM	File folder	
4-data-visualization_files	9/21/2023 12:02 AM	File folder	
data	9/20/2023 11:51 PM	File folder	
img	9/20/2023 11:10 PM	File folder	
libs	9/21/2023 4:17 AM	File folder	
1-introduction-to-r.pdf	9/20/2023 9:47 AM	Adobe Acrobat Docu...	4,090 KB
2-data-wrangling.pdf	9/20/2023 9:48 AM	Adobe Acrobat Docu...	5,163 KB
1-introduction-to-r.html	9/20/2023 1:34 AM	Chrome HTML Docu...	30 KB
2-data-wrangling.html	9/20/2023 5:44 AM	Chrome HTML Docu...	33 KB
3-descriptive-statistics.html	9/20/2023 10:37 PM	Chrome HTML Docu...	27 KB
4-data-visualization.html	9/21/2023 4:17 AM	Chrome HTML Docu...	26 KB
df_tbilisi_50.csv	9/20/2023 5:12 AM	Microsoft Excel Com...	2 KB
total_income.csv	9/20/2023 5:11 AM	Microsoft Excel Com...	1 KB
vat_liability_small_2019.png	9/21/2023 4:18 AM	PNG File	63 KB
exercises-session1.R	9/20/2023 1:51 PM	R File	1 KB
exercises-session2.R	9/20/2023 11:50 PM	R File	1 KB
exercises-session4.R	9/21/2023 3:18 AM	R File	3 KB
202309.Rproj	9/20/2023 7:34 PM	R Project	1 KB
.Rhistory	9/20/2023 1:51 PM	RHISTORY File	3 KB
1-introduction-to-r.Rmd	9/20/2023 1:34 AM	RMD File	24 KB
2-data-wrangling.Rmd	9/20/2023 5:44 AM	RMD File	27 KB
3-descriptive-statistics.Rmd	9/20/2023 11:17 PM	RMD File	21 KB
4-data-visualization.Rmd	9/21/2023 4:16 AM	RMD File	24 KB

Gráficos de barras

Uma nota sobre sintaxe

- A visualização de dados geralmente requer várias iterações para adicionar novos elementos ao seu código inicial e melhorar seu gráfico
- `ggplot2` adiciona novos elementos a uma visualização com o símbolo `+`
- Mais personalização significa que seu código pode facilmente se tornar bastante longo. Usar espaços e quebras de linha ajuda na clareza, mas **simplesmente não há como evitar isso**

Exercício 1:

```
ggplot(base_nfe) +  
  aes(x = mes_emissao,  
       y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS de pequenas empresas em
```


Exercício 2

```
ggplot(base_nfe) +  
  aes(x = as.factor(mes_emissao),  
       y = vicms) +  
  geom_col() +  
  labs(title = "Total de ICMS por mês",  
       x = "Mês",  
       y = "Valor ICMS (R$)") +  
  scale_x_discrete(labels = c("Outubro", "Novembro", "  
  theme(plot.title = element_text(hjust = 0.5)) + 21 / 56
```

Gráficos de linha


Gráficos de linha

- Em visualização de dados, chamamos de **codificações** a geometria selecionada para representar os dados visualmente
- Nos exemplos anteriores, fizemos isso quando usamos `geom_col()`. Isso diz ao R que nossa codificação para representar os dados são **barras** (também chamadas de colunas)
- `ggplot2` tem várias opções diferentes para codificações em visualização de dados, por exemplo: **linhas**
- A codificação para linhas no `ggplot2` é `geom_line()`



Gráficos de linha

- No entanto, eles geralmente também requerem alguma manipulação adicional de dados em comparação com gráficos de barras: os dados devem ser agrupados no nível especificado no eixo x e variável de agrupamento
- Isso ficará mais claro no próximo exercício. O gráfico que produziremos está abaixo




Exercício 2a: Agrupe seus dados no nível mês-grupo

Use o seguinte código para criar um dataframe agrupado no nível mês-emissor e calcular o ICMS total para cada emissor em cada mês

```
df_group_month <- base_nfe %>%  
  filter(emitcnpj8_anon %in% c(34942603, 23356886, 33756669)) %>%  
  select(emitcnpj8_anon, mes_emissao, vicms) %>%  
  group_by(emitcnpj8_anon, mes_emissao) %>%  
  summarize(total = sum(vicms)) %>%  
  ungroup()
```

Gráficos de linha

O resultado se parecerá com isso, você pode explorá-lo com `View(df_group_month)`.

A screenshot of the RStudio interface. The top pane shows the file '4-data-visualization-br.Rmd' and a data frame 'df_group_month'. The bottom pane displays a table with 4 columns: an index, 'emitcnpj8_anon', 'mes_emissao', and 'total'. The table contains 9 rows of data. The interface includes navigation arrows, a filter icon, and a 'Filter' label.

	emitcnpj8_anon	mes_emissao	total
1	23356886	10	42619.78
2	23356886	11	36606.21
3	23356886	12	26298.31
4	33756669	10	37866.61
5	33756669	11	30887.45
6	33756669	12	30056.55
7	34942603	10	69602.66
8	34942603	11	58278.73
9	34942603	12	60879.32


Gráficos de linha

Exercício 2b: Criar um gráfico de linha do ICMS por mês e grupo

```
ggplot(df_group_month) +  
  aes(x = mes_emissao,  
      y = total) +  
  geom_line(aes(color = as.factor(emitcnpj8_anon))) +  
  labs(title = "Total de ICMS por empresa-mes",  
       x = "Mês",  
       y = "ICMS (R$)") +  
  scale_x_continuous(breaks = c(10,11,12)) +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  theme_classic()
```


Gráficos de linha

Seu resultado possivelmente se parece com isso:



Gráficos de linha

Podemos melhorá-lo fazendo alguns ajustes: **tornar os rótulos da legenda, títulos e textos do eixo x menores** e **rotular o título da legenda**



Gráficos de linha

Exercício 2c: Continue melhorando seu gráfico


1. Adicione o argumento `legend.text=element_text(size=7)` dentro de `theme()` para diminuir o tamanho do texto da legenda
2. Adicione o argumento `legend.title=element_text(size=7)` dentro de `theme()` para diminuir o tamanho do texto do título da legenda
3. Adicione o argumento `axis.text.x=element_text(size=6)` dentro de `theme()` para diminuir o tamanho do texto do eixo x
 - note que ambos os argumentos precisam ser separados por vírgula
4. Adicione a linha `labs(color = "Emissor")` para mudar o título da legenda

O resultado deve ser este:

```
ggplot(df_group_month) +  
  aes(x = mes_emissao,y = total) +  
  geom_line(aes(color = as.factor(emitcnpj8_anon))) +  
  labs(title = "Total de ICMS por grupo de empresas em 2019",x = "Mês",y = "ICMS (R$)") +  
  scale_x_continuous(breaks = c(10,11,12)) +  
  theme_classic() +  
  labs(color = "Emissor") +  
  theme(legend.text = element_text(size = 7), # não esqueça a vírgula!  
        legend.title = element_text(size = 7), # não esqueça a vírgula!  
        plot.title = element_text(size = 9),  
        axis.text.x=element_text(size=6))
```

Gráficos de linha

Seu gráfico deve ser algo assim:



Gráficos de linha

Exercício 2d: salve seu gráfico

Use este código para salvar seu gráfico:

```
ggsave("base_nfe_icms_emissor.png",  
        width = 20,  
        height = 10,  
        units = "cm")
```




Gráficos de linha

Name	Date modified	Type	Size
2-data-wrangling_cache	9/19/2023 3:40 PM	File folder	
3-descriptive-statistics_cache	9/20/2023 7:01 PM	File folder	
4-data-visualization_cache	9/20/2023 11:23 PM	File folder	
4-data-visualization_files	9/21/2023 12:02 AM	File folder	
data	9/20/2023 11:51 PM	File folder	
img	9/20/2023 11:10 PM	File folder	
libs	9/21/2023 4:17 AM	File folder	
1-introduction-to-r.pdf	9/20/2023 9:47 AM	Adobe Acrobat Docu...	4,090 KB
2-data-wrangling.pdf	9/20/2023 9:48 AM	Adobe Acrobat Docu...	5,163 KB
1-introduction-to-r.html	9/20/2023 1:34 AM	Chrome HTML Docu...	30 KB
2-data-wrangling.html	9/20/2023 5:44 AM	Chrome HTML Docu...	33 KB
3-descriptive-statistics.html	9/20/2023 10:37 PM	Chrome HTML Docu...	27 KB
4-data-visualization.html	9/21/2023 4:17 AM	Chrome HTML Docu...	26 KB
df_tbilisi_50.csv	9/20/2023 5:12 AM	Microsoft Excel Com...	2 KB
total_income.csv	9/20/2023 5:11 AM	Microsoft Excel Com...	1 KB
vat_liability_small_2019.png	9/21/2023 4:39 AM	PNG File	79 KB
vat_liability_small_2019_by_group.png	9/21/2023 4:42 AM	PNG File	192 KB
exercises-session1.R	9/20/2023 1:51 PM	R File	1 KB
exercises-session2.R	9/20/2023 11:50 PM	R File	1 KB
exercises-session4.R	9/21/2023 4:22 AM	R File	3 KB
202309.Rproj	9/20/2023 7:34 PM	R Project	1 KB
.Rhistory	9/20/2023 1:51 PM	RHISTORY File	3 KB
1-introduction-to-r.Rmd	9/20/2023 1:34 AM	RMD File	24 KB
2-data-wrangling.Rmd	9/20/2023 5:44 AM	RMD File	27 KB
3-descriptive-statistics.Rmd	9/20/2023 11:17 PM	RMD File	21 KB
4-data-visualization.Rmd	9/21/2023 4:21 AM	RMD File	25 KB

Gráficos de linha

Escolher a codificação correta para seus dados pode ser complicado. Depende do que você quer mostrar em seu gráfico e quanta informação você quer que ele mostre


- **Gráficos de barras** mostram menos informações que gráficos de linha em geral, mas são bons para casos em que você tem apenas uma variável numérica e uma variável categórica para mostrar
- **Gráficos de linha** podem mostrar mais informações e incluir múltiplos grupos para adicionar uma dimensão adicional aos seus dados, mas não são visualmente atraentes quando seus dados variam muito de uma categoria para outra



Codificações de texto


Codificações de texto

- Formas geométricas como barras e linhas não são a única maneira de codificar dados em gráficos
- Também podemos usar texto diretamente para representar informações no gráfico, como no exemplo abaixo. Isso é chamado de **codificações de texto**
- Codificações de texto podem ser combinadas com codificações geométricas para destacar informações ou fornecer detalhes importantes adicionais à sua visualização



Codificações de texto

- Usar codificações de texto em gráfico de barras pode ser esclarecedor
- No entanto, também requer manipulação adicional de dados: os dados precisam ser agrupados no mesmo nível do eixo x para poder adicionar codificações
- Veremos isso no próximo exercício




Exercício 3a: Agrupe seus dados no nível mensal

Isso é similar ao que fizemos no exercício 2a, exceto que desta vez o agrupamento é no nível mensal em vez do nível mês-grupo. Use o código abaixo para armazenar o dataframe agrupado em `df_mes`

```
df_mes <- base_nfe %>%  
  select(mes_emissao, vicms) %>%  
  group_by(mes_emissao) %>%  
  summarize(total = sum(vicms))
```

Codificações de texto

Esse deve ser o resultado que você pode ver usando `View(df_mes)`



The screenshot shows the RStudio interface with a file named '4-data-visualization-br.Rmd*' and a data frame 'df_mes' open. The data frame has 3 rows and 3 columns: 'mes_emissao' and 'total'. The first column is an index (1, 2, 3). The 'mes_emissao' column contains values 10, 11, and 12. The 'total' column contains values 280444.6, 223777.8, and 228007.6.

	mes_emissao	total
1	10	280444.6
2	11	223777.8
3	12	228007.6

Codificações de texto


Exercício 3b: Adicione codificações ao seu gráfico de barras

Use o dataframe agrupado `df_mes` e o código anterior do exercício 1 para adicionar codificações ao seu gráfico de barras. O resultado é o código abaixo:

```
ggplot(df_mes) +  
  aes(x = mes_emissao,  
      y = total) +  
  geom_col() +  
  geom_text(aes(label = total),  
            position = position_dodge(width = 1),  
            vjust = -0.5,  
            size = 3) +  
  labs(title = "Total de ICMS por mês",  
        x = "Mês",  
        y = "ICMS (R$)") +  
  theme_classic() +  
  theme(plot.title = element_text(hjust = 0.5))
```


Codificações de texto

Este resultado é bom, mas as codificações de texto têm várias casas decimais. Podemos melhorá-lo arredondando `total` com a função `round()`




Codificações de texto

Exercício 3c: Melhore seu gráfico mais uma vez

Substitua `total` por `round(total)` em `geom_text()`. O resultado deve ser:

```
ggplot(df_mes) +  
  aes(x = mes_emissao,  
      y = total) +  
  geom_col() +  
  geom_text(aes(label = round(total)),          #<- Mudança vai aqui  
            position = position_dodge(width = 1),  
            vjust = -0.5,  
            size = 3) +  
  labs(title = "Total de ICMS por mês",  
        x = "Mês",  
        y = "ICMS (R$)") +  
  scale_x_continuous(breaks = 201901:201912) +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  theme_classic()
```

Codificações de texto



Codificações de texto

Não se esqueça de salvar seu gráfico!


Use este código para salvar este último gráfico:

```
ggsave("nfe_totals_text.png",  
        width = 20,  
        height = 10,  
        units = "cm")
```

Gráficos de dispersão

Gráficos de dispersão

- Vamos explorar mais um tipo de codificação para visualizações de dados: **gráficos de dispersão** (*scatter plot*)
- Gráficos de dispersão são úteis quando você tem duas variáveis numéricas contínuas e quer mostrar que pode haver uma correlação entre elas ou visualizar outliers (valores que se destacam do resto porque são muito extremos)
- Usamos a codificação `geom_point()` para gráficos de dispersão




Gráficos de dispersão

Exercício 4: Criar um gráfico de dispersão

Use o seguinte código para reproduzir o gráfico de dispersão do último slide:

```
ggplot(base_nfe) +  
  aes(x = vprod,  
      y = vicms) +  
  geom_point() +  
  labs(title = "ICMS vs. valor produto",  
       x = "Valor Produto (R$)",  
       y = "Valor ICMS (R$)") +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  theme_classic()
```

Gráficos de dispersão



Gráficos de dispersão

Por último, lembre-se de salvar seu gráfico de dispersão com:

```
ggsave("scatter_vprod_icms.png",  
        width = 20,  
        height = 10,  
        units = "cm")
```

Conclusão

Conclusão

Outras codificações no `ggplot2`


Esta tabela lista várias das codificações mais populares no `ggplot2`

Codificação	Função no <code>ggplot2</code>
Barras	<code>geom_col()</code>
Linhas	<code>geom_line()</code>
Pontos (gráfico de dispersão)	<code>geom_point()</code>
Área	<code>geom_area()</code>
Histograma	<code>geom_histogram()</code>
Etiquetas flutuantes (textos)	<code>geom_text()</code>
Box plot	<code>geom_boxplot()</code>
Gráfico de pizza	<code>geom_bar() + coord_polar()</code>
Linha suavizada	<code>geom_smooth()</code>

Conclusão

Salve seu código!


Clique no disquete para salvar seu código em um local que você lembrará.



```
exercises-session4.R x
Source on Save
Run Source
4 # Exercise 1a
5 library(ggplot2)
6 ggplot(small_business_2019_all) +
7   aes(x = taxperiod,
8       y = vat_liability) +
9   geom_col() +
10  labs(title = "Total VAT liability of small businesses in 2019")
11
12 # Exercise 1b
13 ggplot(small_business_2019_all) +
14   aes(x = taxperiod,
15       y = vat_liability) +
16   geom_col() +
17   labs(title = "Total VAT liability of small businesses in 2019")
18   # x-axis title
19   x = "Month",
20   # y-axis title
21   y = "Georgian Lari") +
22   # telling R not to break the x-axis
23   scale_x_continuous(breaks = 201901:201912) +
24   # centering plot title
25
```


Conclusão

Pipeline de trabalho com dados



Conclusão

Olhando adiante



Conclusão

Olhando adiante

- Conectando R com bancos de dados SQL. Algumas bibliotecas:

- `dbConnect`
- `dbplyr`
- `DBI`

- Mais sobre manipulação de dados. Mais bibliotecas:

- `tidyr`
- `janitor`
- `data.table`

- Mais sobre visualização de dados

Obrigado!
